

Prediksi Estimasi Nilai Belanja Kafe dengan Mempertimbangkan Faktor Inflasi



Disusun Oleh:

Nama : Yunanda Mario Putra

Nim ; A11.2024.15923

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2026

1. Pendahuluan dan Latar Belakang

Industri kafe merupakan salah satu sektor kuliner yang tumbuh pesat, namun rentan terhadap ketidakpastian permintaan harian. Pemilik kafe seringkali kesulitan memperkirakan potensi pendapatan sebelum sebuah transaksi selesai diproses, terutama saat harus mengambil keputusan operasional secara cepat (misalnya stok bahan baku atau penjadwalan staf).

Proyek ini bertujuan membangun model machine learning yang dapat memperkirakan estimasi nilai belanja (Total Spent) sebuah transaksi kafe hanya berdasarkan pilihan menu dan konteks transaksi (waktu, lokasi, metode pembayaran), sekaligus mempertimbangkan kondisi inflasi bulanan sebagai faktor eksternal makroekonomi. Dataset yang digunakan adalah dirty_cafe_sales.csv dari Kaggle (10.000 transaksi, sengaja mengandung data kotor berupa placeholder ERROR/UNKNOWN, missing value, dan duplikat) yang digabungkan dengan data inflasi bulanan Bank Indonesia.

Tujuan bisnis proyek ini adalah menyediakan alat bantu estimasi pendapatan (revenue forecasting) secara real-time bagi pemilik kafe, dengan metrik kesuksesan berupa nilai RMSE serendah mungkin pada data uji, tanpa mengorbankan interpretabilitas model bagi stakeholder non-teknis.

2. Metodologi

Alur kerja (pipeline) proyek ini terdiri dari 7 tahap utama sebagaimana diilustrasikan berikut:

Data Acquisition -> Data Cleaning -> Feature Engineering -> Modeling & Tuning -> Evaluation -> Interpretation -> Deployment (Streamlit)

2.1 Data Acquisition

Dua sumber data digabungkan: (1) dirty_cafe_sales.csv berisi transaksi harian kafe pada tahun 2023, dan (2) Data_Inflasi.xlsx berisi tingkat inflasi bulanan dari Bank Indonesia. Penggabungan dilakukan melalui kunci Bulan-Tahun.

2.2 Data Cleaning

Data mentah mengandung placeholder ERROR/UNKNOWN pada berbagai kolom. Langkah pembersihan meliputi: konversi placeholder menjadi NaN, konversi tipe data numerik dan tanggal, penghapusan baris tanpa Item/Quantity/Price/Tanggal transaksi (tidak dapat direkonstruksi), rekonstruksi Total Spent dari Quantity x Price Per Unit bila kosong, pengisian kategori 'Unknown' untuk Payment Method dan Location yang kosong, penghapusan duplikat Transaction ID, serta penghapusan outlier ekstrem pada Total Spent menggunakan metode IQR ($1.5 \times IQR$). Setelah proses ini, jumlah data berkurang dari 10.000 menjadi sekitar 7.500 baris transaksi bersih.

2.3 Feature Engineering

Fitur tambahan yang diturunkan dari Transaction Date meliputi Year, Month, DayOfWeek, dan IsWeekend. Fitur Inflasi diperoleh dari hasil join dengan data inflasi bulanan. Perlu dicatat bahwa Quantity dan Price Per Unit sengaja TIDAK dipakai sebagai fitur model karena $\text{Total Spent} = \text{Quantity} \times \text{Price Per Unit}$ secara matematis persis; jika keduanya diikutsertakan sebagai fitur maka model hanya akan belajar operasi perkalian sederhana (menghasilkan $R^2=1.0$ yang trivial dan tidak bermakna secara pembelajaran mesin, atau dikenal sebagai data leakage). Fitur final yang digunakan adalah: Item, Payment Method, Location (kategorikal) serta Inflasi, Year, Month, DayOfWeek, IsWeekend (numerik). Encoding dilakukan dengan One-Hot Encoding untuk fitur kategorikal dan Standard Scaling untuk fitur numerik, keduanya disatukan dalam satu sklearn Pipeline.

2.4 Modeling & Evaluation

Data dibagi menjadi training (70%), validation (15%), dan test (15%) set. Dua model regresi dilatih dan dibandingkan: Linear Regression sebagai baseline, dan Random Forest Regressor yang di-tuning menggunakan GridSearchCV (parameter `n_estimators`, `max_depth`, `min_samples_split`, dengan 3-fold cross validation berbasis metrik `neg_root_mean_squared_error`).

Tabel Perbandingan Performa Model

Model	R2 (Test)	MAE (Test)	MSE (Test)	RMSE (Test)
Linear Regression	0.4010	3.4374	17.9692	4.2390
Random Forest	0.3868	3.4915	18.3966	4.2891

Berdasarkan tabel di atas, model Linear Regression dipilih sebagai model terbaik karena memiliki RMSE terendah pada test set sekaligus lebih mudah diinterpretasikan (koefisien linear) dibandingkan Random Forest. Kedua model menunjukkan performa yang relatif setara, mengindikasikan bahwa hubungan antara fitur dan target sebagian besar bersifat linear (didominasi oleh perbedaan harga dasar antar item menu).

2.5 Interpretasi Model

Interpretasi dilakukan menggunakan Permutation Importance dan SHAP (TreeExplainer pada model Random Forest). Kedua metode secara konsisten menunjukkan bahwa fitur Item (jenis menu yang dipilih) merupakan faktor paling dominan dalam menentukan estimasi nilai belanja, jauh melampaui fitur lain seperti waktu transaksi maupun tingkat inflasi.

2.6 Deployment

Model terbaik (disimpan sebagai `models/best_model.pkl`, mencakup seluruh pipeline preprocessing) diintegrasikan ke dalam aplikasi web interaktif berbasis Streamlit yang terdiri dari 5 halaman: Ringkasan Proyek, Dashboard EDA interaktif, Model Demo (form

input untuk prediksi real-time), Evaluasi Model, dan Interpretasi Hasil beserta Dokumentasi.

3. Hasil dan Analisis

Hasil EDA menunjukkan bahwa distribusi Total Spent bersifat right-skewed, frekuensi penjualan antar item relatif merata, dan yang terpenting: tingkat inflasi bulanan memiliki korelasi yang sangat lemah terhadap Total Spent harian (mengindikasikan resiliensi bisnis kafe terhadap gejolak makroekonomi jangka pendek).

Model Linear Regression mencapai R^2 sekitar 0.40 pada data test, artinya sekitar 40% variasi nilai belanja pelanggan dapat dijelaskan oleh kombinasi fitur menu, waktu, lokasi, metode bayar, dan inflasi. Sisanya dipengaruhi oleh faktor acak seperti preferensi individu (quantity yang dibeli, yang secara sengaja tidak dimasukkan sebagai fitur untuk menghindari data leakage).

Analisis residual menunjukkan sebaran error yang relatif simetris di sekitar nol tanpa pola sistematis yang mencolok, mengindikasikan model tidak mengalami bias yang signifikan terhadap rentang nilai prediksi tertentu.

4. Kesimpulan dan Rekomendasi

1. Model Linear Regression dipilih sebagai model produksi karena memberikan keseimbangan terbaik antara akurasi (RMSE terendah) dan interpretabilitas.
2. Pilihan menu (Item) adalah prediktor terkuat nilai belanja pelanggan, sehingga strategi bisnis sebaiknya difokuskan pada bauran menu dan upselling.
3. Inflasi bulanan bukan prediktor kuat terhadap nilai belanja individual, mendukung temuan bahwa bisnis kafe relatif tahan terhadap gejolak ekonomi makro jangka pendek.
4. Untuk pengembangan lebih lanjut, disarankan menambahkan fitur seperti data cuaca, hari libur nasional, atau histori pelanggan (customer loyalty) untuk meningkatkan akurasi prediksi.

5. Referensi

- Kaggle. (2024). Dirty Cafe Sales Dataset. <https://www.kaggle.com/>
- Bank Indonesia. (2024). Data Inflasi Bulanan Indonesia. <https://www.bi.go.id/>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825-2830.
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.
- Streamlit Inc. (2024). Streamlit Documentation. <https://docs.streamlit.io/>